Problem 1: Explore the Marabou Resources Directory

모델: nnet, onnx, h5 포멧이 제공된다. Nnet 포멧의 architecture는 완전연결 신경망이다. Onnx 포멧의 architecture는 복잡한 모델이고, h5 포멧은 keras 모델을 저장하기 위한 포멧이다.

데이터셋: mnist, cifar10, german_traffic_sign(독일 교통표지판), ACUX XU, Collision Avoidance, twin stream dataset이 존재한다.

쿼리: BNN 강건성에 대한 쿼리, built-in property query(Collision Avoidance, Twin Stream), Acas property, mnist dataset에 대한 쿼리가 존재한다.

Problem 2: Run Marabou with an External Model and Dataset

```
Network: resources/nnet/acasxu/ACASXU_experimental_v2a_2_7.nnet
Number of layers: 8. Input layer size: 5. Output layer size: 5. Number of ReLUs: 300
Total number of variables: 610
Property: resources/properties/acas_property_3.txt

Engine::processInputQuery: Input query (before preprocessing): 309 equations, 610 variables
Engine::processInputQuery: Input query (after preprocessing): 604 equations, 838 variables

Input bounds:
        x0: [ -0.3035,  -0.2986]
        x1: [ -0.0095,   0.0095]
        x2: [  0.4934,   0.5000]
        x3: [  0.3000,   0.5000]
        x4: [  0.3000,   0.5000]

Branching heuristics set to LargestInterval
unsat
```

설치는 문제없이 완료되었으며 한가지에 대해 테스트해 본 결과 잘 작동되었다.

이번에 사용한 데이터셋은 Fashion-MNIST으로 흑백 의류 데이터셋이다. 총 클래스는 10개로 T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot가 있다. 데이터셋은 28X28X1이다. 픽셀값은 0~255이지만 0~1사이로 변환하여 모델을 학습시켰다. 사용한 모델은 우선 28X28 크기의 이미지를 784차원으로 Flatten 한다. 이후 각 레이어는 순차적으로 16, 32, 64, 128, 256, 128, 64, 32, 16개의 크기를 가지며 비선형성을 위해 ReLU 활성화 함수를 적용한다. 마지막 출력층은 분류를 위한 10개의 Logit 값을 반환한다. 검증 쿼리는 입력 제약 조건과 출력 제약 조건을 명시했다. 입력 제약 조건은 이미지에서 물리적으로 불가능한 값을 탐색하지 않도록, 각 픽셀의 값을 x라고 했을 때, $[\max(0, x-\epsilon), \min(1, x+\epsilon)]$ 범위로 Clipping 하였다. 출력 제약 조건은 허용된 섭동 범위에서 모델이 원본 클래스 보다 오답 클래스의 Logit 값을 더 높게 출력하는 조건을 만족하는지 검사하도록 설정했다.

검증 대상으로는 모델이 올바르게 분류한 원본 이미지 5장을 선정하였으며, 입력 섭동의 허용 범위인 epsilon 값을 0.001, 0.003, 0.005, 0.045로 점진적으로 조절하며 취약성을 분석했다. 네트워크의 깊이와 복잡도로 인한 과도한 연산 시간을 방지하고자 각 검증의 타임아웃(Timeout)을 3분으로 제한했다. 또한, 검증 과정 중 SAT(Satisfiable) 판정이 발생할

경우, 이는 주어진 epsilon 범위 내에 모델을 기만할 수 있는 적대적 반례가 존재하여 공격에 취약함을 의미하므로 불필요한 추가 탐색을 막기 위해 즉시 검증을 종료하도록 파이프라인을 수정했다.

Image	Epsilon	Final Result	Total Time(s)
image0	0.001	SAT	7.95
image0	0.003	SAT	7.83
image0	0.005	SAT	8.46
image0	0.045	SAT	913.26
image1	0.001	UNSAT	3.87
image1	0.003	UNSAT	3.67
image1	0.005	UNSAT	3.69
image1	0.045	UNSAT	12.74
image2	0.001	UNSAT	3.87
image2	0.003	UNSAT	3.77
image2	0.005	UNSAT	3.65
image2	0.045	UNSAT	3.58
image3	0.001	UNSAT	3.87
image3	0.003	UNSAT	3.78
image3	0.005	UNSAT	3.71
image3	0.045	UNSAT	3.64
image4	0.001	UNSAT	3.55
image4	0.003	UNSAT	3.64
image4	0.005	UNSAT	3.56
image4	0.045	SAT	10.02

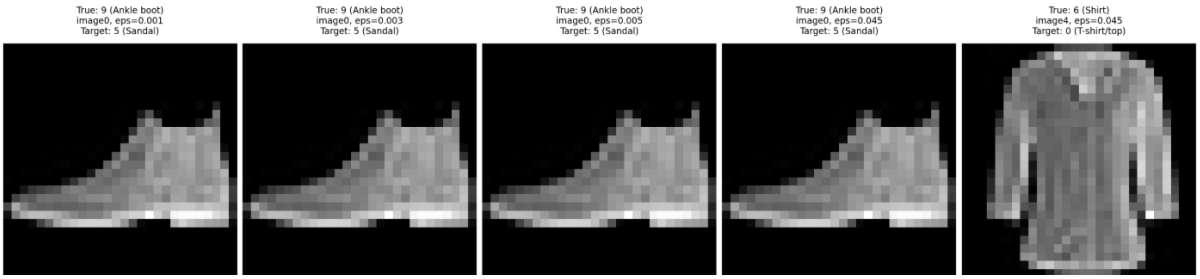

위 결과는 1번 이미지에 대해 모든 epsilone에 대해 SAT가 발생하였으며 그때 정답은 Ankle boot였지만 Sandal으로 오분류했다. 또한 5번 이미지에 대해 epsilone이 0.045일 때 SAT가 발생했으며 정답은 Shirt였지만 T-shirt/top으로 오분류 했다. 각각의 소요시간은 UNSAT인 경우 대부분 3초 내외였지만 12초 소요된 경우도 존재했다. SAT인 경우 7~8초에서 10초, 15분까지 소요되는 경우도 존재했다.

본 실험을 통해 확인한 Marabou의 장점은 입력 및 출력 제약 조건을 통해 신경망의 강건성을 직관적이고 수학적으로 엄밀하게 검증할 수 있다는 것이다. 하지만 실제 적용 관점에서는 두 가지 뚜렷한 한계점이 존재함을 확인했다.

첫째, 확장성의 한계이다. 본 실험에 사용된 다이아몬드형 MLP는 현대의 딥러닝 모델에 비하면 상대적으로 단순한 구조임에도 불구하고 15분이나 소요될 정도로 막대한 연산 시간이 소요되었다. 이는 SMT 기반 검증의 고질적인 조합 폭발 문제로, 규모가 큰 모델에는 적용하기 어렵다는 것을 보여준다.

둘째, 지원 연산의 제한성이다. 모델 설계 단계에서 활성화 함수로 ELU를 적용하고자 했으나, Marabou 환경에서 이를 지원하지 않아 검증에 실패했다. 즉, ReLU와 같은 특정 부분 선형 함수 외에는 사용 가능한 비선형 연산이 매우 제한적이라는 단점이 있다.